

Transkriptionsrichtlinien „Digitalisierung und Volltexterkennung der ehemals Reichenauer Inkunabeln“

Stand: 31.03.2024.

Im Rahmen des Projektes „Digitalisierung und Volltexterkennung der ehemals Reichenauer Inkunabeln“ digitalisierte die Badische Landesbibliothek die 243 Titel umfassende Inkunabelsammlung aus der ehemaligen Bibliothek des Klosters Reichenau und erschloss diese im mit Hilfe des Texterkennungssystems Transkribus. Die Digitalisate und Volltexte sind über die Digitalen Sammlungen der Badischen Landesbibliothek verfügbar (<https://digital.blb-karlsruhe.de/topic/view/7530707>).

Nachfolgende Transkriptionsrichtlinien wurden innerhalb des Projektes für die computergestützte Transkription von Inkunabeln und Frühdrucken definiert. Insbesondere liegen sie dem Trainingsmaterial der auf der Transkribus-Plattform veröffentlichten Texterkennungsmodelle

- „Latin Incunabula (Reichenau)“ (Modell-ID 61337),
- „Latin/German Bilingual Incunabula (Reichenau)“ (Modell-ID 61316) und
- „German Incunabula (Reichenau)“ (Modell-ID 61285)

zu Grunde.

Das Projekt wurde von der Stiftung Kulturgut Baden-Württemberg gefördert.



Text














Allgemeine Prinzipien:







- Glyphen werden sprach- und kontextabhängig transkribiert.
- Abkürzungen werden nicht ausgeschrieben. Zu ihrer Wiedergabe werden ausschließlich solche Unicode Zeichen verwendet, die in gängigen Schriftarten darstellbar sind.
- Konsonantische Ligaturen werden in der Transkription aufgelöst.
- Satzfehler bleiben i. A. unkorrigiert. Eine Ausnahme bilden kopfüber gesetzte Buchstaben.
- Es werden s/f, U/V, u/v, i/j unterschieden. Andere Buchstabenvarianten (z.B. ð/d, ʒ/r, I/J, verschiedene M-Formen, ...) werden im Sinne einer höheren Les- und Durchsuchbarkeit vereinheitlicht.
- Handschriftliche Eintragungen werden nur dann transkribiert, wenn sie für das Texterkennungsmodell (nach Binarisierung) voraussichtlich nicht als solche erkennbar sein werden.

Interpunktion





Grundsätzlich werden Satzzeichen an das vorangehende Wort gezogen. Auf sie folgt ein Leerzeichen.

Beispiel	Transkription	Unicode	
	vniuerfalis. Valet	U+002E	FULL STOP
	ad. et	U+002E	FULL STOP













	volo. S ₃	U+002E	FULL STOP
Auch Punkte, die leicht oberhalb der Grundlinie stehen, werden mit U+002E transkribiert.			
	fepat? .f. ab		FULL STOP
Bei Abkürzungen, die konventionell durch beidseitige Punkte markiert sind, wie z.B. für <i>scilicet</i> und <i>enim</i> , werden beide Punkte – von der Grundregel abweichend – an die Abkürzung gezogen.			
	tpalē: f ₃	U+003A	COLON
	est, &	U+002C	COMMA
	fuccendi; Et	U+003B	SEMICOLON
	feipm; qda ₃	U+003B	SEMICOLON
Der punctus elevatus wäre nur über die Private Use Area abbildbar (MUFI: F161, PUA-8), daher wird mit Semikolon transkribiert.			
	tuos?	U+003F	QUESTION MARK
	(batur)	U+0028 U+0029	LEFT PARENTHESIS RIGHT PARENTHESIS
	d ersten (geburt	U+0028	LEFT PARENTHESIS
Auch Klammern, die den Text-„Übertrag“ einer angrenzenden Zeile markieren, werden transkribiert.			
	detur/ et	U+002F	SOLIDUS
	fuisse/ vt	U+002F	SOLIDUS
	¶ Incipit	U+00B6	PILCROW SIGN
	¶ A quo	U+00B6	PILCROW SIGN
	¶ Quintus	U+00B6	PILCROW SIGN
	¶ De	U+00B6	PILCROW SIGN
	¶ Quero	U+00B6	PILCROW SIGN
¶ (U+2E3F) wird nicht verwendet. Handschriftliche Paragraphenzeichen werden mittranskribiert, da die Texterkennungsmodelle sie von gedruckten nur schlecht unterscheiden können.			








	 Sigmundus	U+261E	WHITE RIGHT POINTING INDEX
	ha 	U+00AC	NOT SIGN
	Au 	U+00AC	NOT SIGN
	impera 	U+00AC	NOT SIGN
	prete 	U+00AC	NOT SIGN
U+00AC wird nur verwendet, wo auch ein grafisches Trennzeichen vorhanden ist.			
	rectum  graphia	U+0026	AMPERSAND
	iure  in	U+204A	TIRONIAN SIGN ET
	militare  viuere	U+204A	TIRONIAN SIGN ET
	aüt  significat	U+204A	TIRONIAN SIGN ET
			
Q vnus deus est. ij.			
Auch größere Abstände werden als einzelnes Leerzeichen abgebildet.			
		U+2042	ASTERISM

Zahlen



Beispiel	Transkription
	est.  antiquas
	
Nur bei isoliert stehenden Zahlen werden flankierende Punkte beidseitig an das Zahlzeichen gezogen.	
	
	
	
Arabische Zahlen werden unabhängig von der jeweiligen Form als moderne arabische Zahlzeichen wiedergegeben.	















Buchstaben













Beispiel	Transkription	Unicode	
	Hæc	U+00E6	LATIN SMALL LETTER AE
	Eſchynes.	U+0118	LATIN CAPITAL LETTER E WITH OGONEK
	fabulę	U+0119	LATIN SMALL LETTER E WITH OGONEK
	Cępi	U+0119	LATIN SMALL LETTER E WITH OGONEK
	Iuris	U+0049	LATIN CAPITAL LETTER I
U+004A (LATIN CAPITAL LETTER I) wird nicht verwendet.			
	denarijſ	U+0069 U+006A	LATIN SMALL LETTER I LATIN SMALL LETTER J
Zwischen i und j wird aber differenziert.			
	hñs	U+0069 U+006A	LATIN SMALL LETTER I LATIN SMALL LETTER J
Die Ligatur wird hier aufgelöst. Steht allerdings die Glyphe y für ii/ij, wird mit U+0079 (LATIN SMALL LETTER Y) transkribiert.			
	k	U+006B	LATIN SMALL LETTER K
Das typografisch aus l und 2 zusammengesetzte k wird als einzelner Buchstabe transkribiert.			
	dōnent	U+0364	COMBINING LATIN SMALL LETTER E
	erlōſe	U+0364	COMBINING LATIN SMALL LETTER E
	Fœcerat	U+0153	LATIN SMALL LIGATURE OE
	Orthographia	U+0072	LATIN SMALL LETTER R
	orthographia	U+0072	LATIN SMALL LETTER R
Zwischen geradem r und r rotunda wird nicht unterschieden, einzige Ausnahme ist die Abbraviatur qz.			
	fatiſ		








	hieß	U+00DF	LATIN SMALL LETTER SHARP S
	hauß	U+00DF	LATIN SMALL LETTER SHARP S
Hier greift die sprachabhängige Transkription.			
	Ultimo	U+0055	LATIN CAPITAL LETTER U
	Vel	U+0056	LATIN CAPITAL LETTER V
Bei runder Buchstabenform wird U, bei spitzer Buchstabenform wird V transkribiert.			
	rűffen	U+0075 & U+0364	COMBINING LATIN SMALL LETTER E
	Betrűpt	U+0075 & U+0364	COMBINING LATIN SMALL LETTER E
	sűnde	U+00FC	LATIN SMALL LETTER U WITH DIAERESIS
	űppigkait	U+00FC	LATIN SMALL LETTER U WITH DIAERESIS
Sind zwei getrennte Kreissegmente erkennbar, wird ü transkribiert.			
	fűrsten	U+00FC	
	nűt	U+00FC	
	zű	U+0075 & U+0366	COMBINING LATIN SMALL LETTER O
	dűabolus	U+00FF	LATIN SMALL LETTER Y WITH DIAERESIS
	ethimologiźě[tur]	U+007A	

Abbreviaturen

Beispiel	Transkription	Unicode	
	intendā	U+0101	LATIN SMALL LETTER A WITH MACRON
	questioēs	U+0113	LATIN SMALL LETTER E WITH MACRON


	ītendo	U+012B	LATIN SMALL LETTER I WITH MACRON
	cōstructō	U+014D	LATIN SMALL LETTER O WITH MACRON
	Secūdo	U+016B	LATIN SMALL LETTER U WITH MACRON
Die Transkription unterscheidet nicht, ob die Linie gerade oder leicht geschwungen ist.			
	beniamȳ	U+0233	LATIN SMALL LETTER Y WITH MACRON
	omē	U+0304	COMBINING MACRON
	d̄cis	U+0304	COMBINING MACRON
	mḡr	U+0304	COMBINING MACRON
Abkürzungszeichen, die nicht mit Vokalbuchstaben kombiniert sind, werden durch U+0304 wiedergegeben.			
	ṡtruantur	U+A76F	LATIN SMALL LETTER CON
	placȝ	U+A76B	LATIN SMALL LETTER ET
	perfectōeȝ	U+A76B	LATIN SMALL LETTER ET
	fȝ	U+A76B	LATIN SMALL LETTER ET
	neqȝ	U+A76B	LATIN SMALL LETTER ET
Auch wenn der visuelle Eindruck eher 3 (U+0292, LATIN SMALL LETTER EZH) entspricht, wird dem Sinn entsprechend ȝ gesetzt.			
	deitatꝑ	U+A76D	LATIN SMALL LETTER IS
	ȝitatꝑ	U+A76D	LATIN SMALL LETTER IS
	p̄dicatoȝ	U+0070 & U+0304	COMBINING MACRON
	p̄diolum	U+0070 & U+0304 & U+0328	COMBINING MACRON & COMBINING OGONEK
	tꝑe	U+A751	LATIN SMALL LETTER P WITH STROKE THROUGH DESCENDER














	p̄fodia	U+A753	LATIN SMALL LETTER P WITH FLOURISH
	Q fi	U+A758	LATIN CAPITAL LETTER Q WITH DIAGONAL STROKE
	q̄	U+A759	LATIN SMALL LETTER Q WITH DIAGONAL STROKE
	q̄d	U+A757	LATIN SMALL LETTER Q WITH STROKE THROUGH DESCENDER
	q̄r	U+A75B	LATIN SMALL LETTER R ROTUNDA
	R̄ ^o	U+211F	RESPONSE
	f̄coꝛ	U+A75D	LATIN SMALL LETTER RUM ROTUNDA
	utꝛ	U+A75D	LATIN SMALL LETTER RUM ROTUNDA
	f̄m	U+1E9C	LATIN SMALL LETTER LONG S WITH DIAGONAL STROKE
	opa ^r	U+02B3	MODIFIER LETTER SMALL R
Für die hochgestellte r rotunda als Abkürzung von <i>tur</i> wird U+02B3 (und nicht wie bei <i>ur</i> U+0309) verwendet.			
	grauiorib ^o	U+A770	MODIFIER LETTER US
	tractat ^o	U+A770	MODIFIER LETTER US
	aliq̄b ^o		
Ob die -us Abbreuiatur auf der Grundlinie oder hochgestellt steht, wird nicht unterschieden.			
	p̄ferant̃	U+0309	COMBINING HOOK ABOVE
	iterant̃	U+0309	COMBINING HOOK ABOVE


Da U+1DD1 (COMBINING UR ABOVE) in Standardschriftarten nicht umgesetzt ist, wird stattdessen U+0309 verwendet.			
	<i>vo</i>	U+A75F	LATIN SMALL LETTER V WITH DIAGONAL STROKE
Kreuzt das Abkürzungszeichen das v, wird U+A75F verwendet, ansonsten wird mit U+0313 kombiniert (s.u.).			
	ortho <i>g</i> phia	U+0363	COMBINING LATIN SMALL LETTER A
Da U+1DD3 (COMBINING LATIN SMALL LETTER FLATTENED OPEN A ABOVE) in Standardschriftarten nicht umgesetzt ist, wird stattdessen U+0363 verwendet.			
	<i>ic</i>	U+0363	COMBINING LATIN SMALL LETTER A
In der Transkription der Abkürzung für <i>et cetera</i> wird das hochgestellte a stets dem c zugeordnet.			
	<i>q̃netiā</i>	U+0365	COMBINING LATIN SMALL LETTER I
	<i>q̃buscūq̃</i>	U+0365	COMBINING LATIN SMALL LETTER I
	anti <i>q̃</i> z	U+0366	COMBINING LATIN SMALL LETTER O
	<i>vo</i>	U+0313	COMBINING COMMA ABOVE
	iñ <i>t</i>	U+0313	COMBINING COMMA ABOVE
Die Verwendung von U+0313 hängt nicht davon ab, was der Haken abkürzt (<i>er, re, i, ...</i>).			
	credē	U+0313	COMBINING COMMA ABOVE
Auch hier wird dem Sinn folgend U+0313 (für <i>re</i>) gesetzt.			
	vocalĩ	U+0313	COMBINING COMMA ABOVE
	dr̃	U+0313	COMBINING COMMA ABOVE
	fi <i>g̃</i> ficatiōe	U+0313	COMBINING COMMA ABOVE

Hochgestellte Buchstaben

Für hoch- und nachgestellte Buchstaben, wie sie z.B. für Verweise auf Kommenterstellen verwendet werden, wird das nachfolgende Alphabet verwendet:


	res̃	U+00AA	FEMININE ORDINAL INDICATOR
---	------	--------	----------------------------

	actiones ^b	U+1D47	MODIFIER LETTER SMALL B
	psone ^c	U+1D9C	MODIFIER LETTER SMALL C
	ignorentur ^d	U+1D48	MODIFIER LETTER SMALL D
	Umma ^e	U+1D49	MODIFIER LETTER SMALL E
	hoies ^f	U+1DA0	MODIFIER LETTER SMALL F
	publice ^g	U+1D4D	MODIFIER LETTER SMALL G
	cesare ^h	U+02B0	MODIFIER LETTER SMALL H
	iudici ⁱ	U+2071	SUPERSCRITPT LATIN SMALL LETTER I
	¶ Ex ^k	U+1D4F	MODIFIER LETTER SMALL K
	diuturni ^l	U+02E1	MODIFIER LETTER SMALL L
	psensu ^m	U+1D50	MODIFIER LETTER SMALL M
	imitantur ⁿ	U+207F	SUPERSCRITPT LATIN SMALL LETTER N
	nō ^o	U+00BA	MASCULINE ORDINAL INDICATOR
	origo ^p	U+1D56	MODIFIER LETTER SMALL P
	tutis ^q	U+0071	LATIN SMALL LETTER Q
Für das hoch- und nachgestellte q gibt es leider kein passendes Unicode-Zeichen.			
	irrogauit ^r	U+02B3	MODIFIER LETTER SMALL R
	sine ^s	U+02E2	MODIFIER LETTER SMALL S
	subuenit ^t	U+1D57	MODIFIER LETTER SMALL T
	lugdunensi ^u	U+1D58	MODIFIER LETTER SMALL U
	tacito ^v	U+1D5B	MODIFIER LETTER SMALL V
	alia ^x	U+02E3	MODIFIER LETTER SMALL X





	¶ Ome ^y	U+02B8	MODIFIER LETTER SMALL Y
	pfonas ^z	U+1DBB	MODIFIER LETTER SMALL Z

Griechische Buchstaben


Bei griechischen Buchstaben wird zwischen π/π und σ/ς differenziert, die übrigen Buchstabenformen werden vereinheitlicht wiedergegeben.


α. β. γ. δ. ε. ζ. η. θ. ι. κ. λ. μ. ν. ξ. ο. π. ρ. σ. τ. υ. φ. χ. ψ. ω.

Akzente und Spiritus werden so abgebildet, wie sie gesetzt sind – unabhängig davon, ob dies korrekt ist oder modernen Gepflogenheiten entspricht.

	ςπονδεῖος
	κύπρος
	ἔυανδρος
	στυππεία

Die Worttrennung ist so zu setzen, dass ein sinnvoller Text approximiert wird.



ἔπειθ' ὅπερ ἔστι μάλισθ' ὑπὲρ ὕμνων

Layout

Das Seitenlayout wird nur insoweit
annotiert, wie dies für die eigentliche
Texterkennung unabdingbar ist.
Abbildungen und Schmuckelemente
werden nicht kenntlich gemacht.

Textregionen

- Text wird meist großschönig in Textregionen zusammengefasst, eine Unterscheidung nach typografischen Paragraphen erfolgt nicht. Bei mehrspaltigen Layouts erhält jede Textspalte korrekte eine eigene Textregion, um die Lesereihenfolge der zugehörigen Zeilen sicherzustellen.
- Für Textregionen wird nur zwischen den Strukturtypen (type Attribut in Page XML) *paragraph* und *header* unterschieden. Diese Unterscheidung wurde vorgenommen, um eine verbesserte Anzeige der Transkripte zweispaltiger Seitenlayouts vorzubereiten.
- Die Lesereihenfolge wird im Allgemeinen so gesetzt, dass Elemente auf derselben Höhe von links nach rechts geordnet sind (das entspricht dem „smartseder sorting“ in Transkribus). Eine Ausnahme bilden Klammereingaben und vergleichbare Seitenlayouts: Hier steht erst der Haupttext, dann der zugehörige Kommentar.
- Gedruckte Marginalien können je nach Umfang als eigene Textregionen abgebildet werden (eignet sich v.a. für mehrzeilige Marginalien) oder als eigene Zeile in das Transkript des Textblockes eingeschoben werden.
- Bei der Wiedergabe von Diagramminhalten über Textregionen wird auf eine möglichst sinnvolle Lesereihenfolge geachtet.
- Tabellen werden je nach Inhalt und Aufwand werden Tabellen entweder bei der Transkription ignoriert oder als einzelne Textregion mit zeilenweisen Inhalten wiedergegeben.



Zeilen

- Schmuckinitialen und Platzhalter für handschriftliche Initialen werden ignoriert.
- Die Erfassung von Seitenzahlen und Lagensignaturen ist optional.
- Erstrecken sich ganze Wörter über zwei Zeilen (z.B. Lemmata in Wörterbüchern), sind sie in eine separate, in der Lesereihenfolge vorangeordnete Zeile auszugliedern.

